SCI 1402 - Travail noté 1

Martin Laplante - 24121010

Trimestre d'automne 2026

Déposé le 21 septembre 2026

Introduction

Ce que l'IA et la science des données à de noble et intéressant à offrir pour la recherche en général, c'est de pouvoir faire émerger ce qu'on ne voit pas immédiatement dans les données, cela permet une catégorisation objective. On pense, entre autres, aux possibilités qu'offre l'apprentissage non supervisé qui permet l'extraction de caractéristiques émergentes d'un corpus de texte.

Prenons par exemple, l'analyse d'un groupe de publications d'un site de la NASA, le "Astronomy Picture of the Day". Ce site opère depuis 1995 et offre à chaque jour une image différente en lien avec l'astronomie ainsi qu'un texte explicatif l'accompagnant.

Le présent projet propose donc de télécharger le contenu texte de ces articles, d'utiliser la compréhension du langage naturel et la factorisation en matrices non négatives pour faire sortir un jeu de données qui n'est pas apparent à première vue.

Objectifs

Objectifs principaux

Produire un ensemble de caractéristiques qui soit représentatif de ce que la NASA a publié en astronomie durant les 30 dernières années.

Concevoir un système suffisamment ouvert pour permettre un contrôle (ex. ajustement d'une fenêtre glissante) sur la sortie obtenue.

Objectifs secondaires

Explorer les visualisations possibles avec les données extraites. La NASA offre un index de ses archives qui suit un modèle chronologique simple et ne montre que les dix dernières années. Un regroupement comme un index terminologique, sorte de table des matières avec les vignettes des images pourrait s'avérer intéressant.

D'autre part, la programmation orientée objet qu'offre le langage Python est suffisamment avancée pour permettre un développement en composantes réutilisables. De ce fait, en généralisant suffisamment, d'autre type de corpus pourraient être traité avec ce système, moyennant une réécriture de certaines parties.

Le pipeline des données

Voici le pipeline de données proposé

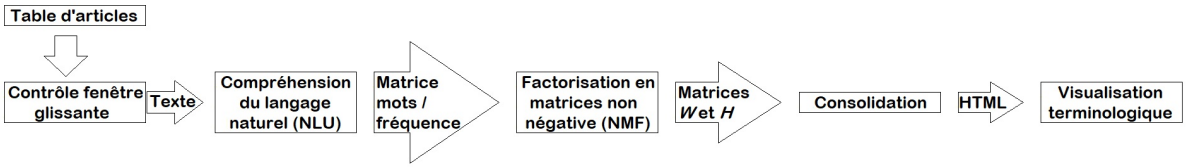


Figure 1: Pipeline des données

Description des composantes à développer

1. Table d'articles
    - C'est un fichier CSV déposé sur Kaggle qui contient les explications des photos publiées sur le site APoD.
2. Contrôle fenêtre glissante
    - Bien que le fichier peut être traité en un seul bloc, l'ajout d'une fenêtre glissante va permettre de localiser dans le temps des caractéristiques plus spécifiques.
    - Une partie de nettoyage devra s'effectuer à ce stade-ci.
3. Compréhension Langage Naturel (NLU)
    - Une fois le bloc de textes sélectionné, on filtre le contenu pour ne garder que les termes significatifs et leur fréquence respective que l'on placera dans une matrice $m \times n$ ou m le nombre d'articles et n le nombre de termes significatifs distinct.
4. Factorisation en matrices non négative (NMF)
    - On utilise ici un module spécialisé Python, NumPy qui permet la création de grandes matrices et leurs opérations.
5. Consolidation
    - Une fois les matrices W et H obtenues, une extraction des caractéristiques va s'effectuer et produire un résultat pour une visualisation
6. Visualisation terminologique
    - Sortie finale un document HTML.

Méthodologie

Le développement va suivre un mode Waterfall, car il répond bien au mode de livraison requis par le cours, à savoir :

1. Ce document, qui montre les bases du projet, sa motivation, ses objectifs
2. Une version de mi-parcours
3. Une livraison fonctionnelle
4. Rapport final du projet.

Un plan sous forme de charte de Gantt est offert en annexe.

Chaîne d'outils

Langage de programmation

Le langage Python est utilisé, car il permet :

1. Prototypage rapide ; Un minimum de code peut être écrit pour valider ou rejeter une idée en cours de chemin
2. Le langage est à sa 3e version majeure et bénéficie d'une très grande communauté d'utilisateurs, ce qui permet d'obtenir des réponses adéquates à la quasi-totalité des problèmes rencontrés pendant le développement
3. Une large communauté d'utilisateurs signifie également qu'on a accès à un large éventail de librairies de qualité, par exemple NumPy dédiée aux opérations numériques complexes (Matrices, Statistiques, etc)

Documentation électronique

Jupyter est utilisé pour fournir un cahier de note virtuel, fonctionnant avec Python.

Grâce à Jupyter, un minimum de code de balise peut être utilisé pour formater un document facile à lire et pouvant comprendre des exemples de codes Python avec les résultats réels intégrés.

Environnement de développement

Durant le certificat, l'utilisation de Google Colab™ s'est montré extrêmement utile pour le développement, en particulier pour :

1. Accélération matérielle gratuite, fortement utile pour les scripts ayant un gros volume de données.

2. Les librairies comme Pandas et NumPy sont déjà prêtes à l'emploi
3. Support intégré Jupyter Notebook

Annexes

A1 - Planification

Voici une décomposition des tâches envisagées. On remarque la création de prototypes afin de faire une découverte hâtive des enjeux le cas échéant

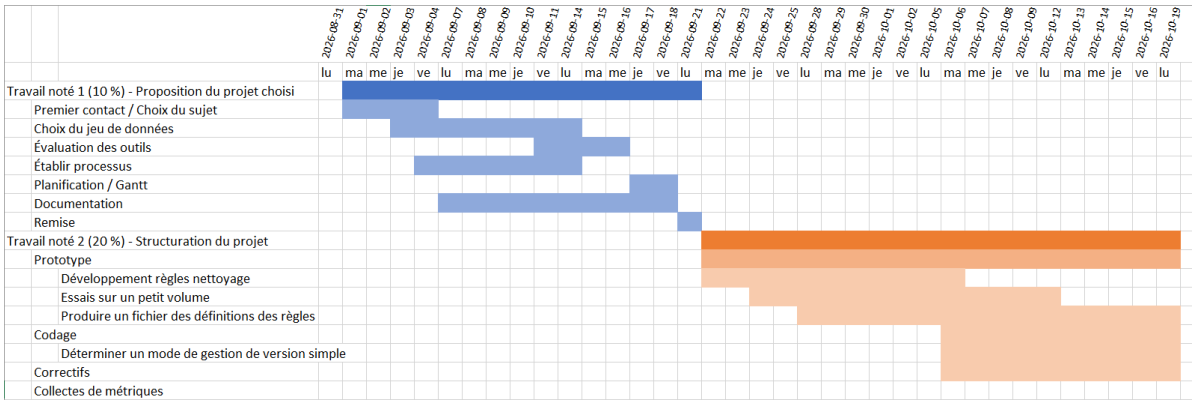


Figure 2: Première partie

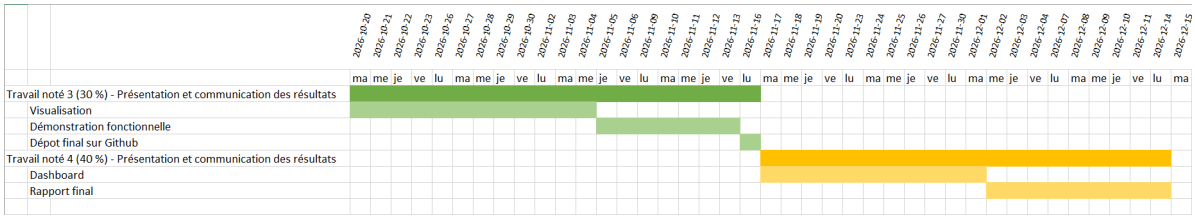


Figure 3: Deuxième partie